Изследване на скалируемостта на Wa-Tor симулацията при статична декомпозиция на домейна

Проект по курса “Системи за паралелна обработка”

Автор:
Иван-Асен Веселинов Чакъров
ФН: 81837, Курс: 3, Група: 1

6 юли 2021 г.

Съдържание

1 Увод

Wa-Tor [3] е класически проблем при паралелното програмиране. Накратко задачата е симулирането на идеализиран двумерен свят с формата на тор. Светът има два вида обитатели - херинги, които играят ролята на плячка и акули, които ловят и изяждат херингите.

Декомпозицията на домейна (Domain decomposition) [4] при паралелното програмиране се явява естествен подход при решаването на проблеми, при които за решаването на проблема за даден елемент D от домейна са нужни само малко подмножество от данни, които са "близо"до D. Накратко, идеята е, че разбиваме домейна на множество поддомейни и възлагаме решаването на проблема за всеки поддомейн на отделен процес. Важно е отделните поддомейни да са със еднаква големина за да може да се разпредели хубаво работата между процесите. Съществуват два вида декомпозиция - статична и динамична. При статичната в началото на алгоритъма разбиваме домейна и разпределяме работата между процесите. По време на симулацията разбиването не се променя, което може да води до намаляване на производителността тъй като данните при доста алгоритми прескачат от един поддомейн в друг и това може да доведе до дисбаланс на работата, която даден процес трябва да свърши. Този проблем се решава от динамичната декомпозиция, която по време на симулацията преизчислява разбиването на домейна с цел балансиране на големината на отделните поддомейни. Декомпозицията на домейни намира приложение при решаването на проблеми от тип Celular automata [5].

Тъй като и Wa-Tor попада в този тип проблеми, представеното решение тук е базирано на статична декомпозиция на домейна.

2 Правилата на света Wa-Tor

Светът на Wa-Tor се намира на повърхността на Тор (или поничка). Цялата повърхност е покрита с вода и единствените обитатели на този свят са херингите, които играят ролята на плячка и акулите, които ловят плячката. Позициите, които заемат рибите (да, акулите са риби) са дискретни и могат да се изобразят с двумерна матрица. Времето тече под формата на дискретни итерации, като на всяка итерация дадена риба променя позицията си, изяжда друга риба, умира или ражда нова себеподобна риба. Точните правила, по които това става са следните:

Движение:

- Херинга: Избира случайна съседна (горна, долна, лява или дясна) свободна клетка и се премества в нея.
- Акула: Избира случайна сеседна клетка с херинга в нея и ако намери такава се мести там и изяжда херингата, а ако няма съседна клетка с херинга се мести на случайна съседна клетка.

Умиране:

- Херинга: При нашата имплементация херингите са безсмъртни. Единственият начин да умрат е ако бедат изядени от акула. В такъв случай биват изтрити от Света. Възможно е да се направи вариант, в който да имат краен живот, в който на всяка итерация губят по една точка енергия и ако стане тя 0 - умират.
- Акула: На всяка итерация ако не изяде някоя херинга губи по една точка енергия. Ако енергията стане 0 умира и бива изтрита от света на Wa-Tor. Ако изяде херинга на дадена итерация и се добавя една точка енергия.

Размножаване:
Еднакво за всички риби. Всяка риба има възраст - число, което започва от 0 при раждане и на всяка итерация се увеличава с 1. Когато дадена риба стигне "максималната възраст"и се нулира възрастта и на старата и позиция се създава нова риба от същия тип (херинга или акула), която е с възраст 0. Възможно е "максималната възраст"да е различна за акулите и херингите.

В интернет има най-различни разновидности на тези правила. Най-вероятно това е, защото в първоизточникът [3] правилата не са описани особено формално описани и, защото много различни имплементации си добавят или променят правила. Има варианти на симулацията, в които и херингите се хранят - с планктон примерно. Нашата имплементация, обаче е базирана на горе описаните правила и изследва скалируемост спрямо тях.

3 Инструкции за употреба на проекта

Програмата се разпространява по 2 основни начина:

- Linux container (Docker): В този вид програмата носи със себе си всички неща на които зависи. За да се пусне на дадена машина трябва да има инсталиран Docker. Това е и използваният начин за изкарването на тестовите резултати.
- Java JAR: Стандартен начин за разпространие на Java базирани програми. Особеност е, че проектът е разработен на Java 16, като използва и експериментални функции на езика, така че препоръчаният начин за използване е през Linux container-а.

Примерни команди в Bash за пускане на програмата:

```
docker run -e ARGS='
  $threads \
  $iterations \
  $sharks \
  $fish \
  $height \
  $width' \
  ivanasen-wator:0.0.1
```

Listing 1: Пускане на програмата през Docker

```
java -jar ivanasen-wator.jar \
  $threads \
  $iterations \
  $sharks \
  $fish \
  $height \
  $width
```

Listing 2: Пускане на програмата директно през Java

Значение на аргументите:

- $threads: Брой нишки
- $iterations: Брой итерации, през които да мине симулацията
- $sharks: Брой акули
- $fish: Брой херинги
- $height: Височина на полето
- $width: Широчина на полето

Пример за резултатът от изпълнението, който се изкарва на стандартния изход:

```
NThreads: 1
Iterations: 100
Shark count: 10000
Fish count: 1000000
Height: 6000
Width: 3000
Execution time millis: 400143
```

Интересният ред е Execution time millis - времето за изпълнение в милисекунди прекарано изпълнявайки симулацията от началото на работата на първата $Worker$ нишка до края на изпълнението на последната. Повече за $Worker$ нишките обясняваме във следващата секция.

4 Описание на паралелния алгоритъм

Алгоритъмът, който позлваме се базира на статична декомпозиция на домейна. Начинът, по който работи е следният. Да кажем, че искаме да изпълним алгоритъма с N на брой нишки. Разбиваме полето на N на брой непрекъснати участъка (поддомейна) по редове като гледаме големината им да е еднаква. Ако височината H не се дели точно на N прибавяме остатъка към последния поддомейн. След това възлагаме всеки поддомейн на отделна нишка, която си изчислява симулацията само за него. Друг подход за разбиване би бил по "правоъглници тоест да имаме по няколко поддомейна на ред. Изборът да го направим по редове е по 2 причини. Едната е, че така всеки поддомейн си комуникира само

с 2 съседа вместо с 4, което намалява времето за комуникация между отделните нишки, а втората причина е, че този алгоритъм е по-прост за реализация.

След като сме разпределили поддомейните на нишките начинът, по който те си синхронизират работата е следния. Всяка нишка обработва своя участък по редове, като започва от най-горния. След като го обработи изпраща съобщение, че е свършила работа по него на нишката, която отговаря за съседния горен участък. След това обработва вътрешните си редове без да праща никакви съобщения на никого, подобно на еднонишкова имплементация. Преди да стигне най-долния ред изчаква да получи съобщение от нишката отговаряща за съседния долен участък, че си е свършила работа по нейния пръв ред. След като го е получила завършва с обработката и на последния ред. Така завършва една итерация от Wa-Tor симулацията за една нишка. След това нишката продължава със следващата итерация, пак започвайки от първия ред.
В нашата имплементация на този алгоритъм използваме нишки, семафори и споделена памет за комуникация. На следващата страница представяме с псевдокод стъпките, които изпълнява една нишка за една итерация.

Нека $rowMutex[i]$ е семафор с начална стойност 1 за $i \in 1...H$. Този семафор играе ролята на мютекс за достъп до даден ред на полето с номер i. Нека $isUpdated[i]$ е семафор с начална стойност 0 за $i \in 1...H$. Отново тези семафори са номерирани по редовете на полето. Служат за уведомяване, че първия ред от участъка на дадена нишка е обработен. Нека $startRow$ и $endRow$ са съответно номера на първия и последния ред, който дадена нишка трябва да обработи.

for $i \leftarrow startRow; i \leq endRow; i \leftarrow i + 1$ **do**
    $nextRow \leftarrow (i + 1) \mod H$
    if $i = startRow$ **then**
        ACQUIRE($rowMutex[i]$)
    else if $i = endRow$ **then**
        ACQUIRE($isUpdated[nextRow]$)
        ACQUIRE($rowMutex[nextRow]$)
    end if
    UPDATESTATEFORROW(i)
    if $i = startRow$ **then**
        RELEASE($rowMutex[i]$)
        RELEASE($isUpdated[i]$)
    else if $i = endRow$ **then**
        RELEASE($rowMutex[nextRow]$)
    end if
end for

Както виждаме този псевдокод е малко по-формална версия на алгоритъма, който описахме с думи.
Друго интересно нещо при алгоритъма ни е начинът по който представяме двумерния свят, в който се намират обитателите на Wa-Tor. Освен, че използваме двумерна матрица за представянето на клетките имаме и масив от свързани списъци от класа Creature, който представлява обитателите на даден ред от полето. Тоест ако искаме да обработим даден ред ние трябва да итерираме свързания списък. Това спестява много посещения на празни клетки, които имплементацията само със двумерна матрица прави.
Цялостно, алгоритъмът като имплементация е подобен на този във [2], но е опростена версия, тъй като използва статична декомпозиция на домейна, т.е. не правим никакъв Load balancing по време на изпълнение и само разбиваме домейна в началото.

5 Архитектура

Решението е имплементирано на Java 16 и използва вградените способности за паралелно програмиране използвайки нишки и споделена памет:

- Thread: Класът за нишка в Java
- ExecutorService: Упрявлява множество нишки в даден Thread pool
- ReentrantLock: Мютекс
- Semaphore: Семафор

Важно е да отбележим, че при имплементацията на JVM, която ползваме (OpenJDK 16) нишките са истински на ниво ядро на операционната система, тъй като има стари версии на JVM и нови разработки като Project Loom [1], при които се използва тъй наречения Green Thread модел, при който нишките се менежират от самата JVM и позволяват мултиплексиране на много JVM нишки върху една ОС нишка.

Архитектурата на проекта е направена по модела Master-Slaves, тъй като имаме една главна нишка, която управлява множество Worker нишки, които извършват изчисленията необходими за симулацията.

Ще отбележим по-важните класове на програмата:

- Creature (и наследниците му Fish и Shark): В Creature е общата логика за това как се държи даден обитател в нашия свят. Fish и Shark съдържат специфичните правила, по които се движат по полето.
- State: Представлява имплементацията за състоянието, в което се намира нашия свят.
- Worker: Този клас имплементира Runnable. Той представлява кода, който се изпълнява от една нишка върху даден участък от света. Инстанциите на класа играят ролята на slaves в нашия модел.
- World: Този клас играе ролята на Master. В него се съдържа логиката за създаването и управлението на отделните Worker-и използвайки ExecutorService.

- Simulation: Създава World и мери времето за изпълнение на N на брой итерации на State.
- GuiSimulation: Създава World и показва в графичен вид в реално време как тече симулацията. Тук използваме Java Swing и AWT за целта.

На следващата страница представяме UML клас диаграма на проекта.

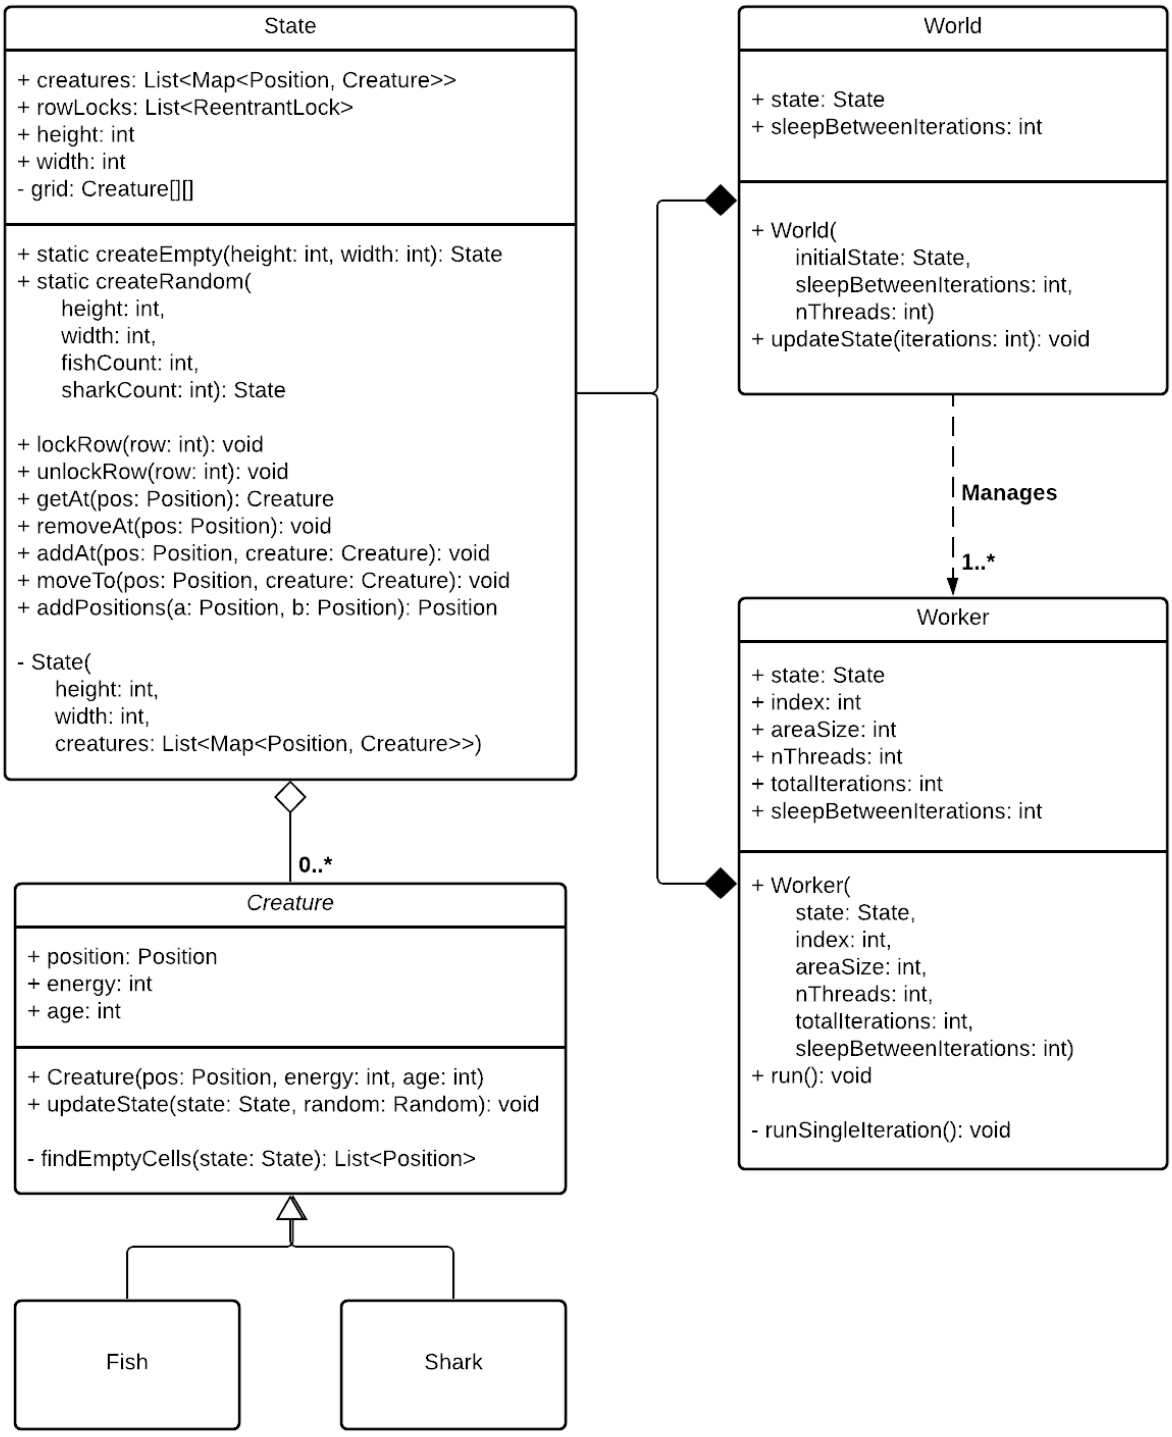

Фигура 1: UML Клас диаграма на проекта

Хубаво е да знаем и начинът, по който тези класове си взаимодесйтват по време на изпълнение на приложението. По тази причина показваме и UML Sequence диаграма.

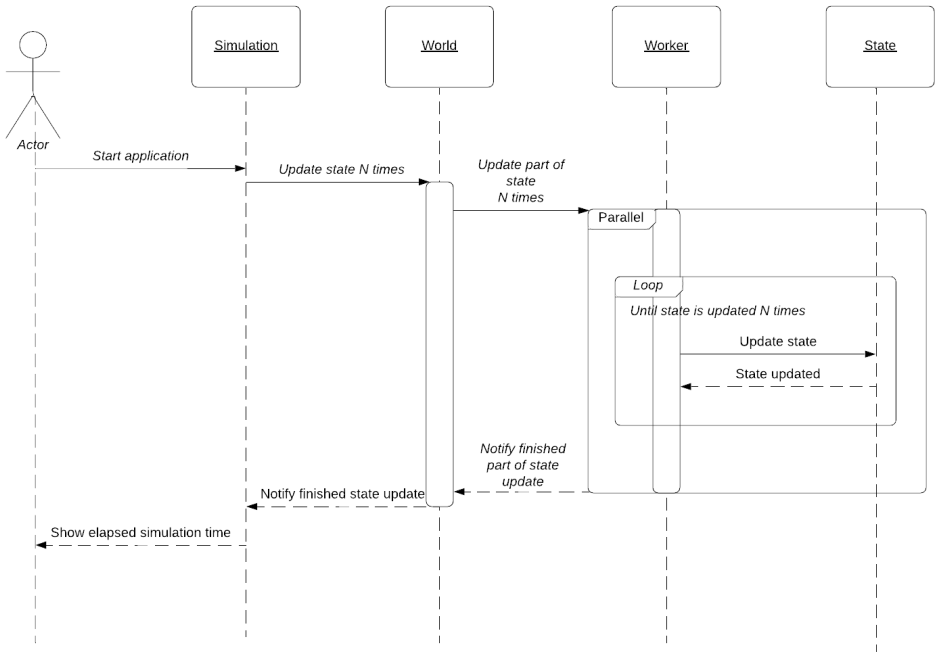

Фигура 2: UML Sequence диаграма на проекта

Разказано с думи това, което се случва по време на изпълнение е следното. Изпълнението започва с класа Simulation, тъй като в него е main метода за Java. Първоначално той си създава инстанция на State, която е със случайно разпределение на рибите из полето. След това създава и World обект, като му подава State. Първоначалното създаване на графа на обекти в приложението не е изобразен на Sequence диаграмата, тъй като не е част от основния алгоритъм, който се опитваме да паралелизираме. Всички описани неща до сега се случват последователно на Main нишката на JVM. След това Simulation пуска заявка на World да се ъпдейтне за N итерации, като преди това започва и измерване на времето за изпълнение. World след това използвайки ExecutorService пуска p на брой нишки, като ги разпределя всяка да работи на отделен последователен брой от редове от полето. Всяка нишка обработва своята част

от полето за N итерации, като същевременно си комуникира и се синхронизира със своите съседи. След като всички нишки завършат работа World разбира това благодарение а ExecutorService-а и връща резултат на Simulation, че е завършила своята работа. Simulation след това измерва точно колко време е минало от момента, в който е дал заявка на World да направи симулацията до момента в който е получил резултат и изкарва полученото време в милисекунди на стандартния изход (stdout).

Правилата на които е базиран Wa-Tor ни принуждават да използваме генератори на случайни числа при всеки избор на това в каква посока трябва да се придвижи дадена риба. По тази причина за да намалим недетерминистичното поведение и да получим по-предвидими тестови резултати използваме винаги еднакъв seed за всички създаващи се инстанции на Random класа в Java. Всяка нишка си има отделна инстанция, която се инициализира със seed равен на номера на самата нишка. По принцип в случаи, в които искаме да генерираме случайни числа от много нишки е хубаво да се използва обект от класа ThreadLocalRandom, който се споделя от различните нишки. Така споделяме обекта и единствено началния seed за всяка нишка е различен. Това е по-добре от използване на цял нов обект за всяка нишка, но в нашия случай искаме да имаме детерминистичен seed за всяка нишка, а във ThreadLocalRandom няма как да се специфицира началния seed, който искаме да ползваме. Затова просто използваме отделни инстанции на Radnom класа.

6 Анализ

Характеристики на тестовата машина:

- Процесор: 2 x Intel® Xeon® CPU E5-2660 0 @ 2.20GHz - Всеки процесор е с по 8 ядра и 2 нишки, това прави 16 ядра общо и 32 нишки (по 2 нишки на ядро благодарение на Hyperthreading).
- Памет: 64Gb, 32K L1d и L1i кешове, 256K L2 кеш и 20480K L3 кеш

Взимайки в предвид броя на нишките на машината има смисъл да тестваме скалируемост с до 32 паралелно работещи нишки.

Начинът по, който са получени резултатите е следният. Пускаме симулацията да върви за N итерации и засичаме времето от началото на

работата на първата $Worker$ нишка до края на работата на последната. Правим отделни измервания от 1 до 32 нишки (не за всеки възможен брой, от съображения за спестяване на време), като правим по 5 за всеки K на брой нишки. След това взимаме най-добрите резултати от тези 5 теста в получените графики тъй като приемаме, че всякакво забавяне е резултат от "шум който се въвежда от работата не други процеси на машината. Най-малкото последните дни преди края на срока за предаването на проектите доста от студентите тестваха на машината и беше трудно да се уцели момент, в който никой друг не тества.

Като грануларност сме тествали единствено с $g = 1$. Основната причина за това беше, че студентът който работеше по този проект най-накрая разбра за какво иде реч под "грануларност"един ден преди крайния срок за проектите. Подзадачите при нас са подполетата на които е разбито голямото поле. Ако броят на подполетата, на които разбиваме нашето поле е N, а имаме p нишки, то $g = N/p$ ни е грануларността. Тъй като рибите постоянно се местят от едно подполе в друго е възможно да се получава дисбаланс на броя на рибите в подполетата по време на симулацията. Един възможен начин да се борим с това е пак да използваме статична декомпозиция на домейна, т.е. разбиваме полето на N подполета в началото и големината им седи константна по време на симулацията и ако изберем $p < N$ можем да разпределяме по някакъв "load balancing"алгоритъм подполетата, които дадена нишка има да изчисли на всяка итерация. Да вземем пример: Да кажем, че сме разбили полето на 2 части по редове и 99% от рибите се намират в долната половина на полето. При $g = 1$, както сме го имплементирали ние първата нишка ще пресметне много бързо нейната половина, докато втората ще смята 99% от времето, а през това време първата няма да прави нищо. Ако го направим с $g = 2$ обаче т.е. да разбием полето по редове на 4 части и отново да имаме 2 нишки, е възможно 2-те да работят първо по долните 2 реда и след това да обработят първите 2. Най-простия начин това да стане е да дистрибутираме работата по отделните "гранули"по псевдослучаен начин. Вторият начин да се борим с този проблем е да променяме големината на поддомейна, който дадена нишка има да обработи. При горния пример вместо да имаме 1% от работата само за горната половина от полето можем да увеличим големината на това подполе да стига например до 3/4 от височината погледнато отгоре надолу. Втората нишка работи единствено по последната 1/4. Така отново постигаме load balancing и

за разлика от разбиването на гранули тук не увеличаваме времето за комуникация между отделните нишки. Също не принуждаваме и свръхтовара върху кеша, който се получава при по-финната грануларност. Пример за такъв алгоритъм със динамична декомпозиция на домейна е Bounded neighbours [2].
Едно нещо, което ни успокоява обаче е, че при Wa-Tor конфигурациите, в които се получават симулации, в които всички животни не умират след някакъв краен брой итерации, тоест "интересните"конфигурации животните най-вероятно ще заемат $> 50\%$ от полето. Нямам доказателство за това за сега, но изглежда, че е вярно съдейки от симулациите, които съм излседвал по време на работа по проекта. Също позициите, които заемат са равномерно разпределни. В такива случаи не се получава особен дисбаланс в поддомейните и един алгоритъм със статична декомпозиция и с едра грануларност е повече от достатъчен за постигане на хубава скалируемост.
Друго нещо е, че тъй като имплементацията ни е на Java и всички обекти се намират на Heap-а (използваме обекти за представянето на рибите) нямаме никаква гаранция за data locality при двумерния масив, в който се пазят рибите, така че свръхтовар на кеша си имаме и при едра грануларност и при фина.

7 Тестови резултати

Изследвали сме скалируемостта при 2 различни набора от параметри:

- $height = 2000, width = 1000, iterations = 200, sharks = 5000, fish = 50000, \# = 10$
- $height = 4000, width = 2000, iterations = 50, sharks = 800000, fish = 1000000, \# = 10$

Идеята да тестваме и при по-голямо поле е да видим как промяната на големината на данните влияе на ускорението. Това, което очакваме е то да е по-добро при по-голямо поле с повече риби. Тъй като пропорционално времето нужно за менежирането на нишките и времето за комуникация между тях е по-малко. Примерно ако полето ни е 2000x1000 при 32 нишки всяка обработва по 60 реда и имайки в предвид , че единствен ред се обработва сравнително бързо, би трябвало да не получаваме

почти никакво ускорение при такъв брой нишки, тъй като времето за синхронизация и самото менежиране на нишките ще изядат всякакви печалби, които получаваме от паралелизма.

Следват таблици с резултатие, които сме получили при тестване.

Значение на таблицитете с резултатите, които сме получили от тестване:

- #: Номер на теста
- p: Брой нишки
- $T_p^{(i)}$: Времето за изпълнение в милисекунди за i-тия тест за p нишки. $i \in 1..5$
- $T_p = min(T_p^{(i)})$
- $S_p = T_p/T_1$
- $E_p = T_p/p$

Ето и самите таблици:

Тестове при размер на полето 1000x2000 и популация 50 000									
#	p	$T_p^{(1)}$	$T_p^{(2)}$	$T_p^{(3)}$	$T_p^{(4)}$	$T_p^{(5)}$	T_p	S_p	E_p
1	1	87521	85238	88839	88392	83791	83791	1.00	1.00
2	2	43636	43001	42122	42790	42451	42122	1.98	0.99
3	4	23608	23848	23023	21739	23980	21739	3.85	0.96
4	8	15380	15380	17515	17541	22925	15380	5.44	0.68
5	12	12934	10676	10307	9834	9906	9834	8.52	0.71
6	16	9089	9315	9004	9134	9245	9004	9.31	0.58
7	20	8826	9019	8913	9056	9033	8826	9.49	0.47
8	24	8716	8628	9207	9010	8833	8628	9.71	0.40
9	28	9462	9054	9910	9264	9493	9054	9.25	0.33
10	32	10150	9903	10275	10361	9935	9903	8.46	0.26

Тестове при размер на полето 4000x8000 и популация 1 000 000									
#	p	$T_p^{(1)}$	$T_p^{(2)}$	$T_p^{(3)}$	$T_p^{(4)}$	$T_p^{(5)}$	T_p	S_p	E_p
1	1	527919	493003	532947	528619	504389	493003	1.00	1.00
2	2	265391	281234	280422	271345	268112	265391	1.85	0.93
3	4	194245	187324	165212	169834	173424	165212	2.98	0.75
3	8	105528	107003	103092	108061	104603	103092	4.78	0.59
4	12	70118	71036	69845	69596	69650	69596	7.08	0.59
5	16	60381	55345	56357	61570	55881	55345	8.91	0.56
6	20	55074	54530	54854	53353	56894	53353	9.24	0.46
7	24	54356	53421	55879	51825	50512	50512	9.76	0.40
9	28	51384	51256	53059	51308	51581	51256	9.62	0.34
10	32	50923	50038	49680	51250	48711	48711	10.12	0.31

Следват графики:

T_p при размер на полето 1000x2000

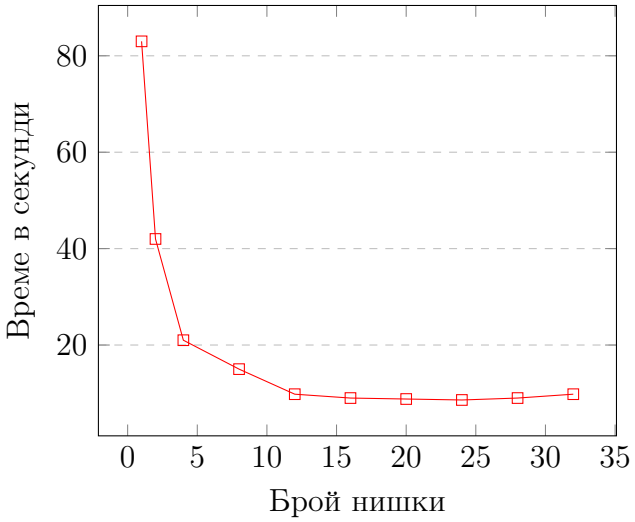

T_p при размер на полето 4000x8000

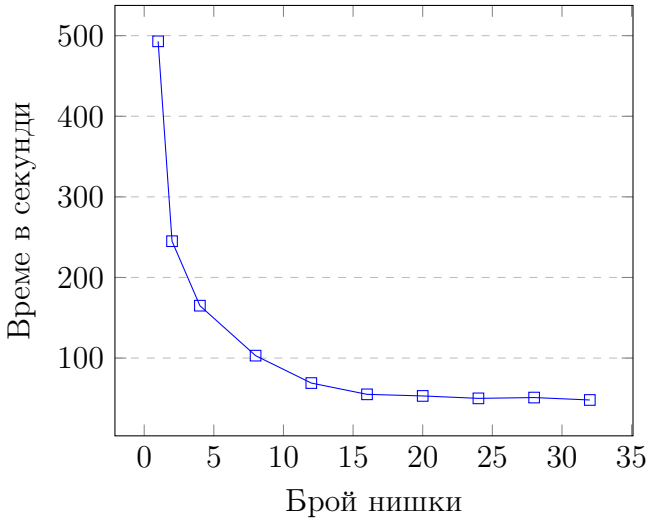

S_p до 16 нишки

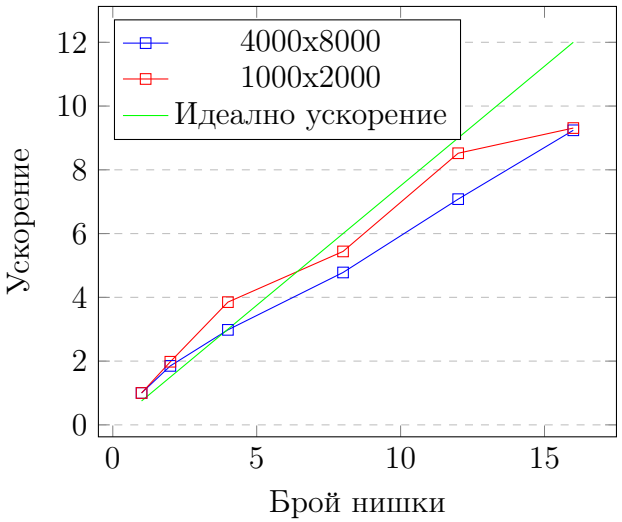

S_p до 32 нишки

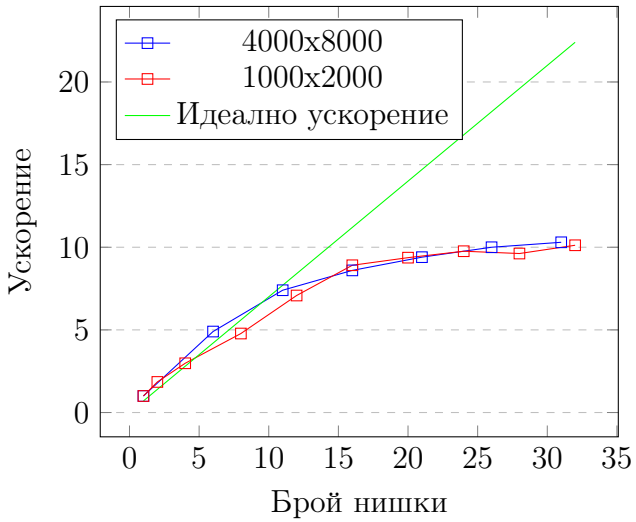

E_p до 32 нишки

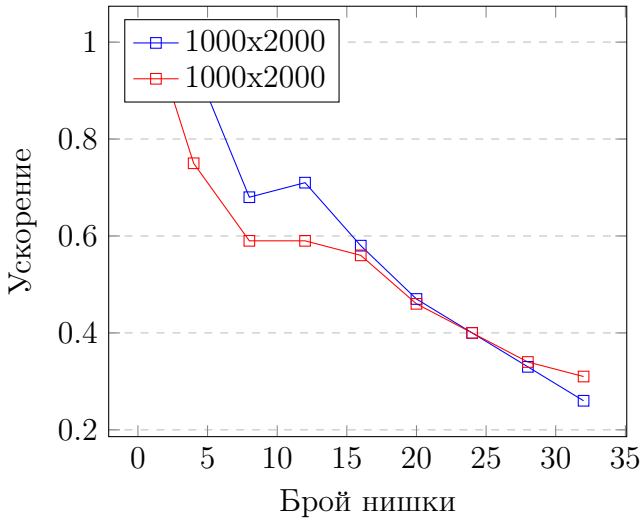

Както виждаме след като минем брой на нишките 16, нямаме почти никакво подобрение от към производителност, т.е. T_p почти не намалява. Това се дължи основна на факта, че машината на която тестваме има само 16 истински процесора, като чрез технологията на Intel наречена Hyperthreading [6] поддържа по 2 нишки на ядро. Това обаче съвсем не замества истинско ядро и се вижда и в нашите резултати.

Също виждаме, че с увеличението на броя нишки се намалява и E_p като това се дължи основно на няколко неща. Първото е, че при големи полета разпределението на животинките се мени доста динамично и се получава дисбаланс на броя риби, които нишките обработват, другото е, че просто с увеличение на броя нишки всяка нишка работи по по-малък брой редове и се увеличава времето нужно за синхронизация между тях. Проблемът с дисбаланса може да се реши ако се имплементира load balancing на броя риби, които дадена нишка обработва, т.е. да се използва динамична декомпозиция на домейна или по-фина грануларност.

Друг проблем е самата природа на езика Java и това, че всички обекти се намират на heap-а, а ние използваме обекти при представянето на рибите, т.е. нямаме никаква гаранция за data locality. Това предизвиква свръхтовар върху кеша дори при едрата грануларност от 1, която ползваме.

Иначе може да се види, че при увеличаване на нишките до 16 получаваме добро подобрение на производителността, като при 16 нишки достигаме около 10 ускорение, което е сравнително добре, взимайки в предвид горните проблеми.

8 Визуализации

Освен симулацията, която служи за измервание на скалируемостта, в проекта е разработена и визуализация в реално време с помощта на Java Swing и AWT. Следват няколко екранни снимки от визуализации (херингите са в зелено, а акулите в синьо):

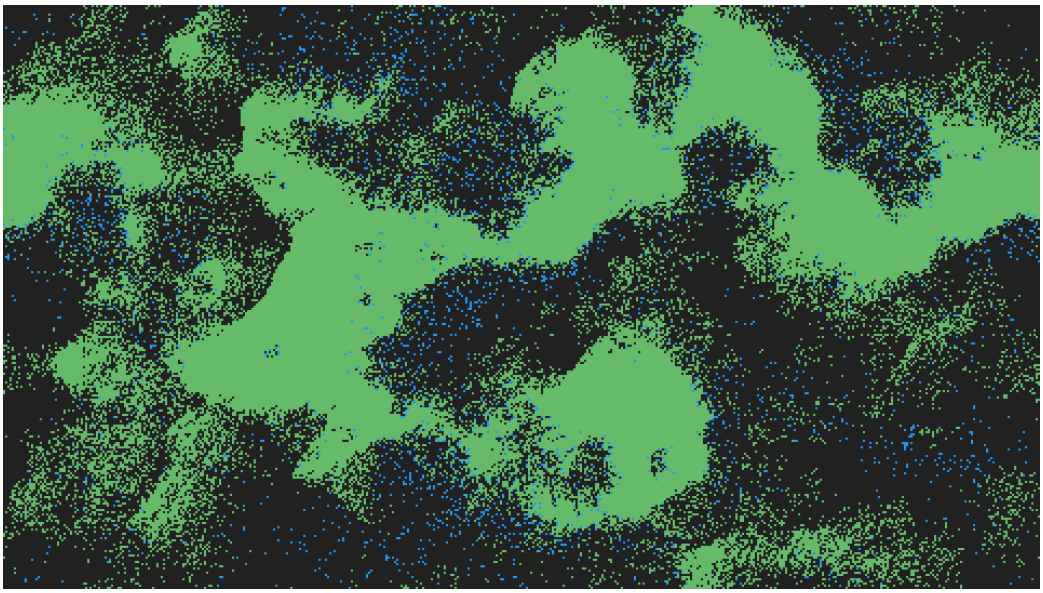

Фигура 3: Размер на полето 480x270, 10 000 херинги и 1000 хиляди акули

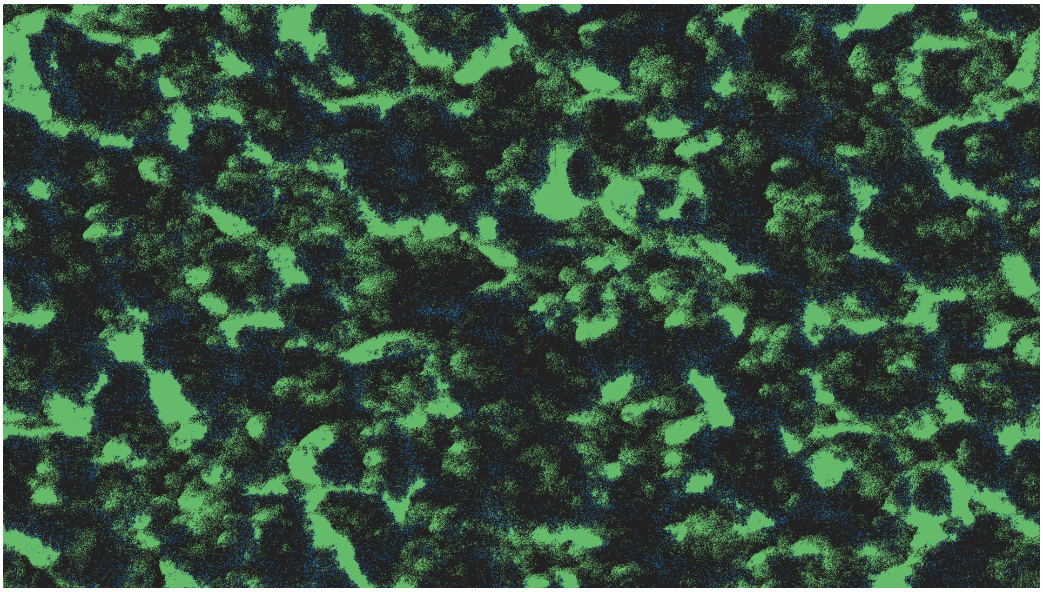

Фигура 4: Размер на полето 1920x1080, 1 000 000 херинги и 100 000 акули

На долния линк може да бъде видяно и видео от симулацията:
`https://drive.google.com/file/d/1YTpRuH6WIVHf_kV8GkType7sPaLtN4y0/view?usp=sharing`

Първоначалната цел на този "режим на работа"беше лесен начин за дебъгване, но в крайна сметка се получи и доста готина анимация, която би могла да бъде доразработена за ползване като screensaver :).

9 Бъдещо развитие на проекта

Резултатите, които са получени при статична декомпозиция на домейна са сравнително хубави, но е възможно да се подобрят с използването на динамична декомпозиция, тоест да правим load balancing на отделните поддомейни по време на изчисленията като променяме големината им. Това помага особено при по-голям размер на полето. Примерни резултати за това какво може да бъде постигнато при използването на такъв тип алгоритъм са дадени във [2] използвайки алгоритъма наречен "Bounded neighbours".

Литература

[1] Project loom: Fibers and continuations for the java virtual machine. *https://cr.openjdk.java.net/ rpressler/loom/Loom-Proposal.html.*

[2] F. Baiardi, A. Bonotti, L. Ferrucci, L. Ricci, and P. Mori. Load balancing by domain decomposition: the bounded neighbour approach. In *In Proc. of 17th European Simulation Multiconference*, pages 9–11, 2003.

[3] Alexander Keewatin Dewdney. Sharks and fish wage an ecological war on the toroidal planet wa-tor. *Scientific American. pp. I4—22*, 1984.

[4] William Gropp. Parallel computing and domain decomposition. *Domain Decomposition Methods for Partial Differential Equations (pp. 349-361)*, 1992.

[5] Peter Sloot and D.Talia. Cellular automata: promise and prospects in computational science. *Future Generation Computing Systems*, 1999.

[6] Jon Stokes. Introduction to multithreading, superthreading and hyperthreading. *Ars Technica. pp. 2–3. Retrieved 30 September 2015.*, 2002.